4. feladat: Continual learning orvosi képosztályozási feladatok között

Részletes hallgatói kutatási specifikáció

Cél	Catastrophic forgetting és task-order hatás vizsgálata egymás után érkező orvosi képosztályozási feladatokon.
Bemenet	Elsődlegesen MedMNIST2D taskok, standard split-ek, egységes backbone, előre definiált task sorrendek.
Kötelező minimum	Sequential fine-tuning, joint-training upper bound, replay, regularization és legalább egy parameter-isolation megoldás.
Elvárt kimenet	Performance matrix, forgetting görbék, BWT/FWT, sorrend-összehasonlítás és ajánlás a task order / similarity szerepéről.

1. Kutatási háttér és motiváció

A continual learning célja, hogy a modell új feladatokat tanuljon meg úgy, hogy közben a korábbi tudást minél kevésbé felejtse el. Orvosi képalkotásban ez releváns lehet, ha egy rendszerhez új modalitások, intézmények vagy diagnosztikai feladatok fokozatosan csatlakoznak.

A MedMNIST több heterogén, de szabványosított classification taskot biztosít, ezért alkalmas task-incremental continual learning protokoll építésére.

Fő kutatási kérdés: Milyen mértékben függ a catastrophic forgetting a feladatok sorrendjétől, és csökkenthető-e a felejtés a task similarity vagy egyszerű continual-learning stratégiák segítségével?

2. Cél

Hozz létre task-incremental protokollt, amelyben a modell egymás után látja a feladatokat, és minden lépés után újraértékeljük az összes addig látott taskot.

Hasonlíts össze több continual-learning stratégiát és több task-sorrendet.

Kutatási kérdések

- Mekkora forgetting jelentkezik sima sequential fine-tuning esetén?
- Mely módszerek csökkentik leghatékonyabban a felejtést adott memória/paraméter budget mellett?
- Befolyásolja-e a sorrend a végső average accuracy-t?
- Hasznos-e hasonló taskokat egymás mellé rendezni?

3. Bemenet és adatforrások

Első körben a MedMNIST 2D taskjai ajánlottak, hogy azonos 2D backbone használható legyen. A 3D taskok később külön sorozatként vizsgálhatók.

- MedMNIST2D standard split-ek.

- Egységes 2D backbone és task-specifikus heads.
- Előre definiált task order listák.
- Replay módszerhez kontrollált memória budget.
- Single-task és joint-training referencia.

Hivatalos elérhetőségek

- MedMNIST official project page (https://medmnist.com/)
- MedMNIST official GitHub repository (https://github.com/MedMNIST/MedMNIST)
- MedMNIST reproducible benchmark experiments (https://github.com/MedMNIST/experiments)
- Official MedMNIST data distribution (Zenodo) (https://doi.org/10.5281/zenodo.10519652)
- MedMNIST v2 paper (Scientific Data) (https://doi.org/10.1038/s41597-022-01721-8)

4. Elvárás - részletes feladat és munkacsomagok

1. munkacsomag - Continual-learning benchmark kialakítása

- Definiáld a task-incremental settinget: a task azonosító inference közben ismert.
- Minden task tanítása után értékeld a modellt az összes korábban látott taskon.
- Ments egy T x T performance matrixot minden seedre.

2. munkacsomag - Task order kísérletek

- Random order több változatban.
- Hasonló taskok egymás után.
- Szándékosan eltérő taskok egymás után.
- Ha lehet, a hasonlósági sorrendet előre definiáld, ne a test eredményekből.

3. munkacsomag - Continual-learning módszerek

- Sequential fine-tuning.
- Replay/exemplar memory.
- Regularization-alapú módszer, például EWC vagy SI.
- Parameter-isolation megoldás, például adapterek vagy részleges freezing.
- Joint training mint nem-continual upper reference.

4. munkacsomag - Memory/compute trade-off

- Replay esetén változtasd a memória budgetet.
- Adapteres megoldásnál mérd a paraméternövekedést.
- Készíts accuracy-vs-resource összehasonlítást.

5. munkacsomag - Task similarity elemzés

- Kapcsold össze a task order eredményeket egyszerű dataset/reprezentációs hasonlósággal.
- Vizsgáld, hogy a hasonló taskok közelsége csökkenti vagy éppen növeli a forgettinget.

5. Javasolt módszertan és kötelező baseline-ok

A projekt elsődleges settingje task-incremental continual learning. Ezt egyértelműen külön kell választani a class-incremental settingtől, ahol inference időben a task azonosító nem ismert.

Kötelező baseline-ok

- Sequential fine-tuning.
- Single-task oracle/reference.

- Joint training upper reference.
- Fixed-size replay buffer.

Javasolt módszerek / továbbfejlesztések

- Elastic Weight Consolidation (EWC) vagy Synaptic Intelligence.
- Learning without Forgetting / distillation alapú stratégia.
- Adapters vagy parameter freezing.
- Similarity-aware task ordering vagy replay sampling.

Fontos: A replay memória méretét abszolút mintaszámban és a teljes korábbi adathoz viszonyított arányban is dokumentáld. Ellenkező esetben a módszerek erőforrásigénye nem összehasonlítható.

6. Kísérleti protokoll és mérőszámok

- Minden task után evaluation az összes addig látott taskon.
- Azonos task sequence ugyanazon seedeknél.
- Task-specific headek használata az elsődleges settingben.
- Validation adat használata early stoppingra taskonként.
- A joint-training reference az összes task adatát egyszerre láthatja, ezért upper reference, nem fair continual baseline.

Javasolt mérőszámok

- Average accuracy az egyes lépések után.
- Average forgetting.
- Backward Transfer (BWT).
- Forward Transfer (FWT), megfelelő referencia mellett.
- Final average accuracy.
- Memory size, extra parameter count és training time.

Kötelező elemzések

- Forgetting curve taskonként.
- Task-order sensitivity.
- Módszerrangsor több sorrend felett.
- Erőforrás/performance Pareto-front.
- Task similarity és forgetting kapcsolat.

7. Elvárt kimenet és leadandók

- Continual-learning pipeline.
- Task x time performance matrix.
- Forgetting/BWT/FWT eredmények.
- Legalább három continual-learning módszer összevetése.
- Legalább három task order összehasonlítása.
- Resource trade-off elemzés.
- Összefoglaló arról, milyen ordering és módszer kombináció működik legjobban.

Reprodukálhatósági és dokumentációs minimum

- A teljes kód legyen verziókezelve (Git), és a repository tartalmazzon rövid, követhető README fájlt.

- Minden kísérlet konfigurációja (modell, optimizer, learning rate, seed, augmentáció, batch size, epochok száma) legyen mentve géppel olvasható formában, például YAML vagy JSON fájlban.
- A train/validation/test felosztást a benchmark hivatalos splitje alapján kell használni, ha ilyen rendelkezésre áll. A tesztkészlet nem használható hiperparaméter-hangolásra.
- Legalább 3 független random seed használata szükséges; ahol a benchmark protokoll ennél többet ír elő, a végső eredményeknél azt kell követni, ha a számítási kapacitás megengedi.
- Az eredményeket nyers formában is el kell menteni (CSV/JSON), nem csak ábrákban. A táblázatok és ábrák legyenek a mentett eredményfájlokból újragenerálhatók.
- A végső beszámolóban az átlagos teljesítmény mellett variabilitást is kell közölni (szórás vagy konfidenciaintervallum).
- A negatív eredményeket és a sikertelen kísérleteket is dokumentálni kell, ha azok módszertani következtetéshez vezetnek.

9. Publikációs továbbfejlesztés

Publikációs irány lehet a task ordering szisztematikus vizsgálata: kevés tanulmány kezeli a sorrendet önálló kutatási változóként heterogén orvosi képi taskok esetén.

További lehetőség egy similarity-aware ordering vagy replay stratégia, amely a task kapcsolatok alapján csökkenti a felejtést.

Opcionális, erősebb kutatási irányok

- Task-agnostic inference / class-incremental kiterjesztés.
- Dynamic adapter allocation.
- Optimal ordering keresése gráf- vagy combinatorial optimization módszerrel.
- Continual learning + domain shift közös vizsgálata.

10. Kockázatok és gyakori hibák

- A task-incremental és class-incremental fogalmak keverése hibás következtetéshez vezet.
- Replay módszer előnye nagymértékben függ a memória budgettől.
- Túl sok task-order kombináció gyorsan kombinatorikus robbanást okoz.
- FWT definíciójához megfelelő random-init vagy single-task referencia szükséges.

11. Hasznos források

A MedMNIST heterogén taskjai egy egységes input/API környezetben teszik lehetővé a continual-learning protokoll felépítését.

- MedMNIST official project page (https://medmnist.com/)
- MedMNIST official GitHub repository (https://github.com/MedMNIST/MedMNIST)
- MedMNIST reproducible benchmark experiments (https://github.com/MedMNIST/experiments)
- Official MedMNIST data distribution (Zenodo) (https://doi.org/10.5281/zenodo.10519652)
- MedMNIST v2 paper (Scientific Data) (https://doi.org/10.1038/s41597-022-01721-8)